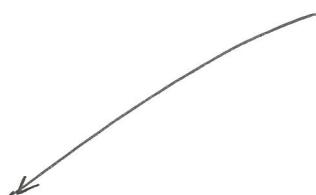


$$Y_i = Y_i(w_i)$$

SUTVA

$$w_i \perp\!\!\!\perp \{Y_{10}, Y_{11}\}$$

random treatment
assignment



SUTVA: stable unit treatment value assumption

1. 单位稳定性: unit stability 受试单位相互独立

2. 单一治疗情况
single treatment level

Lecture 1 Randomized Controlled Trials

随机对照实验

回归在模型分析 RCT 平均治疗效果中的作用

减小方差；但在确定 ATE 中不起作用

$$\Delta_i = Y_i(1) - Y_i(0)$$

$$ATE: \bar{z} = E[Y_i(1) - Y_i(0)]$$

↓ 下面对 \bar{z} 进行估计，建模

*difference-in-means
均值差异估计*

$$\hat{V}_{DM} = \frac{1}{n_1} \sum_{w_i=1} Y_i - \frac{1}{n_0} \sum_{w_i=0} Y_i, \quad nw = |\{i : w_i=w\}|$$

← 改无偏

当使用线性模型时：

$$Y_i(w) = \underbrace{c(w)}_{拟} + \underbrace{X_i \beta(w)}_{\beta} + \varepsilon_i(w)$$

$$E[\varepsilon_i(w)|X_i] = 0, \quad \text{Var}[\varepsilon_i(w)|X_i] = \sigma^2$$

$$\therefore A = \text{Var}[X]$$

$$\|V\|^2 A^2 = V' A V$$

$$\text{则方差 } V_{DM} = 4\sigma^2 + \|(\beta_{(0)} + \beta_{(1)})\|^2 A + \|(\beta_{(0)} - \beta_{(1)})\|^2 A$$

$$\Rightarrow \text{结果: } \bar{z} = E[Y_{(1)} - Y_{(0)}] = c_{(1)} - c_{(0)} + E[X](\beta_{(1)} - \beta_{(0)})$$

$$\text{当用 OLS: } \hat{z}_{OLS} = \hat{c}_{(1)} - \hat{c}_{(0)} + \bar{X} (\hat{\beta}_{(1)} - \hat{\beta}_{(0)})$$

$$\hat{z}_{OLS} - \bar{z} = \underbrace{\hat{c}_{(1)} - c_{(1)}}_{N(0, b^2/n_1)} - \underbrace{(\hat{c}_{(0)} - c_{(0)})}_{N(0, b^2/n_0)} + \underbrace{\bar{X} (\beta_{(1)} - \beta_{(0)})}_{N(0, \|(\beta_{(1)} - \beta_{(0)})\|^2 A / n)} + \underbrace{\bar{X} (\hat{\beta}_{(1)} - \hat{\beta}_{(0)} - \beta_{(1)} + \beta_{(0)})}_{O_p(1/n)}$$

可行

$$\sqrt{n} (\hat{z}_{OLS} - \bar{z}) \Rightarrow N(0, V_{OLS}), \quad V_{OLS} = 4\sigma^2 + \|(\beta_{(0)} + \beta_{(1)})\|^2 A$$

$$\therefore V_{DM} = V_{OLS} + \|(\beta_{(0)} - \beta_{(1)})\|^2 A$$

线性
一元

OLS 在 D 模型中比 difference-in-means 好

证：若模型为：

$$Y_{i(w)} = \mu_{i(w)}(X_i) + \varepsilon_{i(w)}$$

$$E[\varepsilon_{i(w)}|X_i] = 0, \quad \text{Var}[\varepsilon_{i(w)}|X_i] = b^2$$

DV 有：

$$\Rightarrow \sqrt{n}(\hat{\beta}_{Dm} - \beta) \Rightarrow N(0, V_{Dm}) = 4b^2 + 2\text{Var}[\mu_{1(0)}(X_i)] + 2\text{Var}[\mu_{0(0)}(X_i)]$$

Huber-white

OLS 有：求 $(c^*(w), \beta^*(w)) = \arg\min_{c, \beta} \{ E[(Y_{i(w)} - X_i \beta - c)^2] \}$

有 $\star \left\{ \begin{array}{l} \sqrt{n} \left(\left(\frac{\hat{c}(w)}{\hat{\beta}(w)} \right) - \left(\frac{c^*(w)}{\beta^*(w)} \right) \right) \Rightarrow N(0, \begin{pmatrix} MSE^*(w) & 0 \\ 0 & \dots \end{pmatrix}) \\ c^*(w) = E[Y_{i(w)}] \quad MSE^* = E[(Y_{i(w)} - X_i \beta^*(w) - \hat{c}^*(w))^2] \end{array} \right.$

$$\sqrt{n}(\hat{\beta}_{OLS} - \beta) \Rightarrow N(0, V_{OLS}), \quad V_{OLS} = V_{Dm} - \| \beta_{1(0)}^* + \beta_{0(0)}^* \|_A^2$$

$V_{OLS} < V_{Dm}$ 恒成立

小结：OLS 可看作：

$$\hat{\beta}_{OLS} = \frac{1}{n} \sum_{i=1}^n \left(\underbrace{(\hat{c}_{11} + X_i \hat{\beta}_{11})}_{\hat{\mu}_{1(1)}(X_i)} - \underbrace{(\hat{c}_{00} + X_i \hat{\beta}_{00})}_{\hat{\mu}_{0(0)}(X_i)} \right)$$

$\hat{\mu}_{i(w)}(X)$ 可看作在 x 处的 OLS 值；

可试用其它方法

No.

Date

$$\text{m} \mid \sqrt{n} (\hat{\pi}_{\text{AGG}} - \pi) \Rightarrow N(0, V_{\text{AGG}})$$

Proof:

$$V_{\text{AGG}} = \text{Var} [\pi(x_i)] + \sum_{x \in X} \pi^2(x) \frac{1}{\pi(x)} \frac{\delta^2(x)}{e(x)(1-e(x))}$$

$$= \text{Var} [\pi(x_i)] + E \left[\frac{\delta^2(x_i)}{e(x_i)(1-e(x_i))} \right]$$



Lecture 2 Unconfoundedness and the Propensity Score

unconfoundedness 未混杂性：希望去排除混杂因素的影响

propensity score：倾向得分

aggregating difference-in-means estimators 聚合均值差异估计

简单根据 $\{Y_{i(0)}, Y_{i(1)}\} \perp\!\!\!\perp W_i | X_i = x$, for all $x \in \mathcal{X}$

样本量加权

$\rightarrow X_i$ 的值为数值， X_i 是离散的

定义 group-wise ATE：

$$\tau(x) = E[Y_{i(1)} - Y_{i(0)} | X_i = x]$$

$$\hat{\tau}_{AGG} = \sum_{x \in \mathcal{X}} \frac{n_x}{n} \hat{\tau}(x)$$

$$\text{其中 } \hat{\tau}(x) = \frac{1}{n_{x0}} \sum_{\{i: X_i=x, W_i=0\}} Y_i - \frac{1}{n_{x1}} \sum_{\{i: X_i=x, W_i=1\}} Y_i$$

$$n_x = |\{i: X_i=x\}|$$

$$n_{xw} = |\{i: X_i=x, W_i=w\}|$$

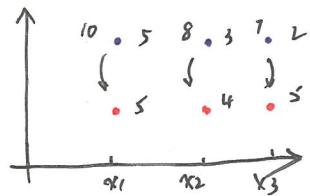
$$\text{再令 } e(x) = P[W_i=1 | X_i=x]$$

$$\begin{aligned} \sqrt{n_x} (\hat{\tau}(x) - \tau(x)) &\Rightarrow N(0, \frac{\text{Var}[Y_{i(0)} | X_i=x]}{1-e(x)} + \frac{\text{Var}[Y_{i(1)} | X_i=x]}{e(x)}) \\ &= N(0, \frac{6^2 \tau(x)}{e(x)(1-e(x))}) \end{aligned}$$

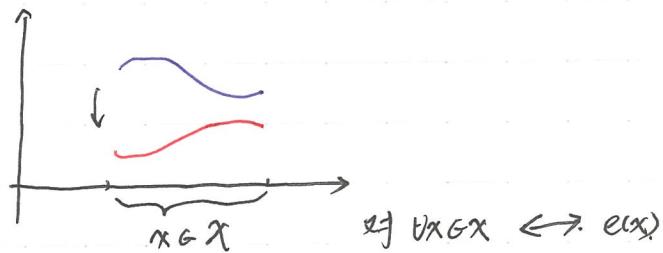
$$\text{再令 } \pi(x) = P[X_i=x] = n_x/n$$

$$\begin{aligned} \hat{\tau}_{AGG} &= \sum_{x \in \mathcal{X}} \hat{\pi}(x) \hat{\tau}(x) = \underbrace{\sum_{x \in \mathcal{X}} \pi(x) \tau(x)}_{N(0, \sum \pi^2(x) \text{Var}[\hat{\tau}(x)])} + \underbrace{\sum_{x \in \mathcal{X}} \pi(x) (\hat{\tau}(x) - \tau(x))}_{+ \sum ((\hat{\pi}(x) - \pi(x)) \tau(x)) + \sum ((\hat{\tau}(x) - \tau(x)) (\hat{\tau}(x) - \tau(x)))} \\ &\quad N(0, n^{-1} \text{Var}[\tau(X_i)]) \quad \text{OP}(\gamma_1) \end{aligned}$$

离散:



连续:



$$\begin{aligned}
 & P[w_i = w | \{Y_{i(0)}, Y_{i(1)}\}, e(x_i)] \\
 &= \int_X P[w_i = w | \{Y_{i(0)}, Y_{i(1)}\}], x_i = x] P[x_i = x | e(x_i)] dx \\
 &= \int_X P[w_i = w | x_i = x] P[x_i = x | e(x_i)] dx \\
 &\text{Lebesgue integration} \\
 &= e(x_i) \mathbb{1}_{w=1} + (1 - e(x_i)) \mathbb{1}_{w=0}
 \end{aligned}$$

归

连续的 X 和 倾向得分:

$\{Y_{i(0)}, Y_{i(1)}\} \perp\!\!\!\perp w_i | X_i$ 在 X_i 下 w_i 无法 peek Y_i ; unconfoundedness

当 $e(x) = P[w_i=1 | X_i=x]$

有

$\{Y_{i(0)}, Y_{i(1)}\} \perp\!\!\!\perp w_i | e(X_i)$

Propensity stratification 倾向分层

1. 将 X_i 排序 s.t.

$$\hat{e}(X_{i1}) \leq \hat{e}(X_{i2}) \leq \dots \leq \hat{e}(X_{in})$$

↙ 分层使对照和实验组更相似

2. 用分层 J 分层，分别计算 J 中的 \hat{e} .

$$\hat{e}_j = \frac{\sum_{j=\lfloor (j-1)n/J \rfloor + 1}^{\lfloor jn/J \rfloor} w_i Y_i}{\sum_{j=\lfloor (j-1)n/J \rfloor + 1}^{\lfloor jn/J \rfloor} w_i} - \frac{(1-w_i) Y_i}{(1-w_i)}$$

3.

$$\hat{e}_{STRAT} = \frac{1}{J} \sum_{j=1}^J \hat{e}_j \quad \text{- 放的 consistent}$$

No.

Date

2019

5

10

15

$$\begin{cases} Y_i(0) = c(x_i) - (1 - e(x_i))\gamma(x_i) + \varepsilon_i(0), & E[\varepsilon_i(0)|x_i] = 0 \\ Y_i(1) = c(x_i) + e(x_i)\gamma(x_i) + \varepsilon_i(1), & E[\varepsilon_i(1)|x_i] = 0 \end{cases}$$

$$\text{Var}[\varepsilon_i(w)|x_i=x] = \delta^2(x)$$

逆概率加权 Inverse-propensity weighting

IPW:

$$\hat{\tau}_{IPW} = \frac{1}{n} \sum_{i=1}^n \left(\frac{w_i Y_i}{\hat{e}(x_i)} - \frac{(1-w_i) Y_i}{1-\hat{e}(x_i)} \right)$$

oracle IPW: 完美已知 $e(x)$

$$\hat{\tau}_{IPW}^* = \frac{1}{n} \sum_{i=1}^n \left(\frac{w_i Y_i}{e(x_i)} - \frac{(1-w_i) Y_i}{1-e(x_i)} \right)$$

若有 overlap $\eta \leq e(x) \leq 1-\eta$ for all $x \in \mathcal{X}$
 也有 $|Y_i| \leq M$:

$$\sup_{x \in \mathcal{X}} |e(x) - \hat{e}(x)| = O_p(\alpha_n) \rightarrow 0$$

有:

$$|\hat{\tau}_{IPW} - \hat{\tau}_{IPW}^*| = O_p\left(\frac{\alpha_n M}{\eta}\right)$$

若 $\hat{\tau}_{IPW}^*$ 一致, 则 $\hat{\tau}_{IPW}$ 也是而 $E[\hat{\tau}_{IPW}^*] = E[Y_i(1) - Y_i(0)]$ unbiased τ .若有 overlap, $\hat{\tau}_{IPW}^*$ 以 $\frac{1}{n}$ 一致于 τ

偏差 PIS

$$\rightarrow n \operatorname{Var}[\hat{\tau}_{IPW}^*] = E\left[\frac{c^2(x_i)}{e(x_i)(1-e(x_i))}\right] + \operatorname{Var}[\tau(x_i)] + E\left[\frac{6^2(x_i)}{e(x_i)(1-e(x_i))}\right]$$

有 $\sqrt{n} (\hat{\tau}_{IPW}^* - \tau) \Rightarrow N(0, V_{IPW}^*)$,

$$V_{IPW}^* = E\left[\frac{c^2(x_i)}{e(x_i)(1-e(x_i))}\right] + \operatorname{Var}[\tau(x_i)] + E\left[\frac{6^2(x_i)}{e(x_i)(1-e(x_i))}\right]$$

$c(x)$ 是 x 与 y 的关系 / 非 x 与 Δy 的关系

对 V_{AGG}

$$V_{IPW*} = V_{AGG} + E \left[\frac{c^2(x_i)}{e(x_i)(1-e(x_i))} \right]$$

→ 除非 $c(x_i)$ 处处为 0, V_{IPW*} 以 V_{AGG} 差

对 W linear modeling

IPW 基以 $\{Y_i(0), Y_i(1)\}$ 且 $W_i | X_i$

LM 依赖线性性。

Lecture 3 Efficient Treatment Effect Estimation via Augmented IPW

原本的普通IPW 大样本特性不好，例如当X为高散时，IPW不如加权求之。

ATE两种特征：

$$\textcircled{1} \quad e(x) = P[W_i=1 | X_i=x]$$

$$\tau = E[\hat{\tau}_{IPW}]$$

$$\hat{\tau}_{IPW}^* = \frac{1}{n} \sum_{i=1}^n \left(\frac{w_i Y_i}{e(x)} - \frac{(1-w_i) Y_i}{1-e(x)} \right)$$

$$\textcircled{2} \quad \mu(w)(x) = E[Y_i(w) | X_i=x]$$

$$\tau(x) = \mu(1)(x) - \mu(0)(x)$$

$$\text{so: } \tau = E[\mu(1)(x) - \mu(0)(x)]$$

$$\hat{\tau}_{REG} = n^{-1} \sum_{i=1}^n (\hat{\mu}_{(1)}(x_i) - \hat{\mu}_{(0)}(x_i))$$

Augmented IPW — AIPW estimator

$$\hat{\tau}_{AIPW} = \frac{1}{n} \sum_{i=1}^n (\hat{\mu}_{(1)}(x_i) - \hat{\mu}_{(0)}(x_i)) + w_i \frac{Y_i - \hat{\mu}_{(1)}(x_i)}{\hat{e}(x_i)} - (1-w_i) \frac{Y_i - \hat{\mu}_{(0)}(x_i)}{1-\hat{e}(x_i)}$$

先用 $\mu(x)$ 估计，再用 IPW 处理回归残差： IPW 使数据过多的特征被公平化

AIPW 的双重稳健性： AIPW consistent if either $\hat{\mu}_{(w)}(x)$ are consistent or $\hat{e}(x)$ is consistent

当 $\hat{\mu}_{(w)}(x) \approx \mu(w)(x)$

$$\hat{\tau}_{AIPW} = \underbrace{\frac{1}{n} \sum_i (\hat{\mu}_{(1)}(x_i) - \hat{\mu}_{(0)}(x_i))}_{\text{consistent}} + \underbrace{\frac{1}{n} \sum_i \left(\frac{w_i}{\hat{e}(x)} (Y_i - \hat{\mu}_{(1)}(x_i)) - \frac{1-w_i}{1-\hat{e}(x)} (Y_i - \hat{\mu}_{(0)}(x_i)) \right)}_{\text{mean}=0}$$

因为 $E[Y_i - \hat{\mu}_{(w)}(x) | X_i, w_i] \approx 0$

把 $e(x)$ 除去了

当 $\hat{e}(x)$ is consistent ($\hat{e}(x) \approx e(x)$)

$$\hat{\tau}_{AIPW} = \frac{1}{n} \sum_{i=1}^n \left(\frac{w_i Y_i}{\hat{e}(x_i)} - \frac{(1-w_i)Y_i}{1-\hat{e}(x_i)} \right) + \frac{1}{n} \sum \left(\hat{\mu}_{(w)}(x_i) (1 - \frac{w_i}{\hat{e}(x_i)}) - \hat{\mu}_{(0)}(x_i) (1 - \frac{1-w_i}{1-\hat{e}(x_i)}) \right)$$

$\underbrace{\quad}_{IPW}$ mean = 0

因为 $E[1 - w_i/\hat{e}(x_i) | x_i] \neq 0$

把 $\hat{\mu}_{(w)}(x_i)$ 带走了

半参数效率：大样本下

AIPW asymptotically optimal 所有非参数估计器 最优

当 $\mu_{(w)}(x)$ 和 $e(x)$ 足够准： $\sqrt{n} (\hat{\tau}_{AIPW} - \hat{\tau}_{AIPW}^*) \xrightarrow{\text{oracle AIPW}} p0$

$\hat{\tau}_{AIPW}^*$ is just an IID average.

$$\sqrt{n} (\hat{\tau}_{AIPW} - \tau) \Rightarrow N(0, V^*)$$

$$V^* = \text{Var}[\tau(x_i)] + E\left[\frac{\delta_0^2(x_i)}{1-e(x_i)}\right] + E\left[\frac{\delta_1^2(x_i)}{e(x_i)}\right]$$

证明了其效果最好，

Cramer-Rao 型约束。

AIPW 和 双重拟合 — 分数据，随机选数据川而验。

分数据 random \rightarrow two halves I_1 and I_2

$$\hat{\tau}_{AIPW} = \frac{|I_1|}{n} \hat{e}^{I_1} + \frac{|I_2|}{n} \hat{e}^{I_2}$$

$$\hat{e}^{I_1} = \frac{1}{|I_1|} \sum_{i \in I_1} \left(\hat{\mu}_{(w)}^{I_2}(x_i) - \hat{\mu}_{(0)}^{I_2}(x_i) + w_i \frac{y_i - \hat{\mu}_{(w)}^{I_2}(x_i)}{\hat{e}^{I_2}(x_i)} - (1-w_i) \frac{y_i - \hat{\mu}_{(0)}^{I_2}(x_i)}{1 - \hat{e}^{I_2}(x_i)} \right),$$

可忽略，asymptotically，我们所选的具体的机器学习调整的特殊性。

只依赖以下条件：

- Overlap : $y < e(x) < 1-y$ for all $x \in X$ ($y > 0$)

- Consistency :

所有机器学习调整方法都有大样本一致性

$$\sup_{x \in X} |\hat{\mu}_{(w)}^{I_2}(x) - \mu_{(w)}(x)|, \quad \sup_{x \in X} |\hat{e}^{I_2}(x) - e(x)| \xrightarrow{P} 0$$

- Risk decay : outcome 和 propensity model 的衰减：

$$E[(\hat{\mu}_{(w)}^{I_2}(x_i) - \mu_{(w)}(x_i))^2] E[(\hat{e}^{I_2}(x_i) - e(x_i))^2] = o(\frac{1}{n})$$

若 $\hat{\mu}_{(w)}$ 和 \hat{e}^I 都 \sqrt{n} -consistent . error $\rightarrow o(1/n^2)$

要满足，一种简单的方式是确保所有回归调整 $o(n^{-1/4})$ ，即以 RMSE 方面较快速度减小

$$\text{注: 反 } \hat{\tau}_{\text{AIPW}} = \frac{|Z_1|}{n} \hat{\tau}^{Z_1} + \frac{|Z_2|}{n} \hat{\tau}^{Z_2}, \quad \hat{\tau}^{Z_i} = \frac{1}{|Z_i|} \sum_{i \in Z_i} \left(\hat{\mu}_{(1)}^{Z_i}(x_i) - \hat{\mu}_{(0)}^{Z_i}(x_i) \right) + \\ w_i \frac{Y_i - \hat{\mu}_{(1)}^{Z_2}(x_i)}{\hat{e}^{Z_2}(x_i)} - (1-w_i) \frac{Y_i - \hat{\mu}_{(0)}^{Z_2}(x_i)}{1 - \hat{e}^{Z_2}(x_i)}$$

反 $\hat{\tau}_{\text{AIPW}}$ 的特征: \checkmark 理想下非反 AIPW

$$\sqrt{n} (\hat{\tau}_{\text{AIPW}} - \hat{\tau}^*) \rightarrow 0$$

证明:

$$\hat{\tau}^* = \frac{|Z_1|}{n} \hat{\tau}^{Z_1,*} + \frac{|Z_2|}{n} \hat{\tau}^{Z_2,*}$$

$$\left\{ \begin{array}{l} \hat{\tau}^{Z_i} = \hat{\mu}_{(1)}^{Z_i} - \hat{\mu}_{(0)}^{Z_i} \\ \hat{\mu}_{(1)}^{Z_i} = \frac{1}{|Z_i|} \sum_{i \in Z_i} \left(\hat{\mu}_{(1)}^{Z_i}(x_i) + w_i \frac{Y_i - \hat{\mu}_{(1)}^{Z_2}(x_i)}{\hat{e}^{Z_2}(x_i)} \right). \end{array} \right.$$

show
⇒ 只需证: $\sqrt{n} (\hat{\mu}_{(1)}^{Z_1} - \hat{\mu}_{(1)}^{Z_1,*}) \rightarrow 0$, 请 P23.

$$\begin{aligned} \hat{\mu}_{(1)}^{Z_1} - \hat{\mu}_{(1)}^{Z_1,*} &= \frac{1}{|Z_1|} \sum_{i \in Z_1} \left(\hat{\mu}_{(1)}^{Z_1}(x_i) + w_i \frac{Y_i - \hat{\mu}_{(1)}^{Z_2}(x_i)}{\hat{e}^{Z_2}(x_i)} - \mu_{(1)}(x_i) - w_i \frac{Y_i - \mu_{(0)}(x_i)}{e(x_i)} \right) \\ &= \frac{1}{|Z_1|} \sum_{i \in Z_1} ((\hat{\mu}_{(1)}^{Z_1}(x_i) - \mu_{(1)}(x_i)) (1 - \frac{w_i}{e(x_i)}) \leq \frac{op(\sqrt{n})}{n} \\ &\quad + \frac{1}{|Z_1|} \sum_{i \in Z_1} w_i ((Y_i - \mu_{(1)}(x_i)) (\frac{1}{\hat{e}^{Z_2}(x_i)} - \frac{1}{e(x_i)})) \\ &\quad - \frac{1}{|Z_1|} \sum_{i \in Z_1} w_i ((\hat{\mu}_{(1)}^{Z_1}(x_i) - \mu_{(1)}(x_i)) (\frac{1}{\hat{e}^{Z_2}(x_i)} - \frac{1}{e(x_i)})) \leq op(\frac{1}{\sqrt{n}}) \end{aligned}$$

K个折叠:

$$\begin{aligned} \hat{\tau}_{\text{AIPW}} &= \frac{1}{n} \sum_{i=1}^n \left(\hat{\mu}_{(1)}^{(-k(i))}(x_i) - \hat{\mu}_{(0)}^{(-k(i))}(x_i) \right. \\ &\quad \left. + w_i \frac{Y_i - \hat{\mu}_{(1)}^{(-k(i))}(x_i)}{\hat{e}^{(-k(i))}(x_i)} - (1-w_i) \frac{Y_i - \hat{\mu}_{(0)}^{(-k(i))}(x_i)}{1 - \hat{e}^{(-k(i))}(x_i)} \right) \end{aligned}$$

效率评分：Efficient Score: $S(\theta) = \frac{d(\log L(\theta))}{d\theta}$ $L(\theta)$ 为似然函数

经验方差：Empirical Variance $\text{Var}(S(\theta))$
 n 个样本集合， $\text{var}(S(\theta)) = \frac{1}{n-1} \sum (S(\theta_i) - \bar{S(\theta)})^2$

有效方差：在定问题下可达最小方差 (C-R 下界有关)

Confidence intervals 置信区间

有效得分为经验方差收敛于有效方差 V^* :

$$\frac{1}{n-1} \sum_{i=1}^n (\mu_{(1)}(x_i) - \mu_{(0)}(x_i) + w_i \frac{y_i - \mu_{(1)}(x_i)}{e(x_i)} - (1-w_i) \frac{y_i - \mu_{(0)}(x_i)}{1-e(x_i)} - \hat{V}^*)^2$$

\hat{V}^* 为非交叉 AIPW:

$$\rightarrow_p V^*,$$

交叉 AIPW 也是 $\hat{V}_{AIPW} \rightarrow_p V^*$:

$$\hat{V}_{AIPW} = \frac{1}{n-1} \sum_{i=1}^n (\hat{\mu}_{(1)}^{(-k(i))}(x_i) - \hat{\mu}_{(0)}^{(-k(i))}(x_i))$$

$$+ w_i \frac{y_i - \hat{\mu}_{(0)}^{(-k(i))}(x_i)}{e^{(\hat{k}(i))}(x_i)} - (1-w_i) \frac{y_i - \hat{\mu}_{(0)}^{(-k(i))}(x_i)}{1-e^{(\hat{k}(i))}(x_i)} - \hat{V}_{AIPW}$$

~~1-a~~

置信 α -level:

$$z \in \left(\hat{V}_{AIPW} \pm \frac{1}{\sqrt{n}} \Phi^{-1}(1-\frac{\alpha}{2}) \sqrt{\hat{V}_{AIPW}} \right),$$

Lecture 4 Estimating Treatment Heterogeneity

估计治疗异质性 对于 (x_i, y_i, w_i) $x_i \in X$

之前我们定义 ATE: $E[Y_i(1) - Y_i(0)]$

异质性分析: conditional average treatment effect.

CATE:

$$\tau(x) = E[Y_i(1) - Y_i(0) | x_i = x]$$

一类 x_i 的 均值

Regularization bias 正则化偏差

对于 $\{Y_i(0), Y_i(1)\}$ 及 $w_i | x_i$:

$$\tau(x) = \mu_{10}(x) - \mu_{00}(x), \mu_{10}(x) = E[Y_i | x_i = x, w_i = 1]$$

problem:

CATE 的估计: $\hat{\tau}_T(x) = \hat{\mu}_{10}(x) - \hat{\mu}_{00}(x)$

该方法的问题: 若样本过少, 会严重正则化 (偏差)
而样本多, 会正确, 但 $\hat{\tau}_T(x)$ 会因 $\hat{\mu}$ 出错.

Semiparametric modeling 半参数建模

与 x_i 的关.

$$Y_i(w) = f(x_i) + w \tau(x_i) + \varepsilon_i(w), P[w_i=1 | x_i] = e(x)$$

where $\tau(x_i) = \psi(x) \cdot \beta$ 一治疗效果的系数

效应与 x 的非参数关系

$$\varepsilon_i = \varepsilon_i(w)$$

在 under confoundness... rewrite

$$Y_i - m(x_i) = (w_i - e(x_i)) \psi(x_i) \beta + \varepsilon_i$$

$$\text{where } m(x) = E[Y_i | x_i = x] = f(x_i) + e(x_i) \tau(x_i)$$

Robinson

注: $Y_i - m(x_i) = \underbrace{(w_i - e(x_i))\psi(x_i)}_{m(x)} \cdot \beta + \varepsilon_i$ where
 $m(x) = E[Y_i | X_i=x] = f(x_i) + e(x_i)\psi(x_i)$

通过上面的式子，设计 residual-on-residual OLS 模型 (残差回归)

$$\begin{cases} \tilde{Y}_i^* = Y_i - m(x_i) \\ \tilde{\varepsilon}_i^* = (w_i - e(x_i))\psi(x_i) \end{cases}$$

只与 X_i Y_i w_i $e(x_i)$
有关，数据预处理。

then:

estimate $\hat{\beta}_R$ by $\tilde{Y}_i^* \sim \tilde{\varepsilon}_i^*$

从而

$$\sqrt{n}(\hat{\beta}^* - \beta) \Rightarrow N(0, V_R), \quad V_R = \text{Var}[\tilde{\varepsilon}_i^*]^{-1} \text{Var}[\tilde{\varepsilon}_i^* \tilde{Y}_i^*] \text{Var}[\tilde{Y}_i^*]^{-1}$$

半参数有效方差

| 当同方差下: $\text{Var}(\varepsilon_i | x_i, w_i) = \sigma^2$ 固定, V_R 为 β 的 semiparametrically efficient variance
不同方差, V_R 依然成立, 但不是半参数有效方差

上述残差回归为理论化的, 因为 $m(x_i)$ 与 $e(x_i)$ 不知;
用交叉验证模拟:

非参数回归

1. non-parametric regression $Y \sim X$ $W \sim X$
 \Rightarrow 得 $\hat{m}(x)$ $\hat{e}(x)$

2. define: $\tilde{Y}_i = Y_i - \hat{m}^{(-k(i))}(x_i)$ 利用去 i 估计的 m
 $\tilde{\varepsilon}_i = (w_i - \hat{e}^{(-k(i))}(x_i))\psi(x_i)$

3. estimate $\hat{\beta}_R$ $\tilde{Y}_i \sim \tilde{\varepsilon}_i$

其中有: $E[(\hat{m}(x) - m(x))^2]^{\frac{1}{2}}$, $E[(\hat{e}(x) - e(x))^2]^{\frac{1}{2}} = o_p(\frac{1}{\sqrt{n}})$

n|

$$\sqrt{n}(\hat{\beta}_R^* - \hat{\beta}_R) \rightarrow_p 0$$

残差

附录：

当治疗效果是常数： $Y_i(w) = f(X_i) + zw + \varepsilon_i$ and $\in [\varepsilon_i | X_i, w_i]$

有：

$$\hat{w}_k = \frac{\sum_{i=1}^n (Y_i - \hat{m}^{(-k(i))}(X_i)) (w_i - \hat{e}^{(-k(i))}(X_i))}{\sum_{i=1}^n (w_i - \hat{e}^{(-k(i))}(X_i))^2}$$
前提：干扰是独立的
收敛足够快
(4.15)

即使 w 非常数，

\hat{w}_k 也会收敛到 $w(x)$ 的一个非负权重的加权平均数

当

$w(x)$ 异质性较低且在重叠方面有困难的情况下，用(4.15)替代

R-1053 -

A loss function for treatment heterogeneity

之前的 estimator : $\hat{z}(x) = \psi(x) \cdot \beta$



大多不是线性，用ML方法：

under confoundness $E[\varepsilon_i(w_i) | X_i, w_i] = 0$, where $\varepsilon_i(w) := Y_i(w) - (\mu(w)(X_i) + w z(X_i))$

$$\mu(w)(x) = E[Y(w) | X=x] \quad \text{for } w \in [0,1]$$

类似之前的 $f(x)$

参照之前的重写上式：

$$Y_i - m(X_i) = (w_i - e(X_i)) z(X_i) + \varepsilon_i$$

where $m(x) = E[Y | X=x] = \mu(w)(X_i) + e(X_i) z(X_i)$

$$\varepsilon_i := \varepsilon_i(w_i)$$

上式也可导价写成：

$$z(\cdot) = \operatorname{argmin}_{z'} \left\{ E \left[\left((Y_i - m(X_i)) - (w_i - e(X_i)) z'(X_i) \right)^2 \right] \right\}$$

$z(m(X_i))$ 可用 $\operatorname{argmin}_{e(X_i)}$ 求出 $z(\cdot)$

$$\hat{z}_R^*(\cdot) = \operatorname{argmin}_{z'} \left\{ \frac{1}{n} \sum_{i=1}^n \left((Y_i - m(X_i)) - (w_i - e(X_i)) z'(X_i) \right)^2 + \lambda_n(z') \right\}$$

$m(x), e(x)$ 不可知 (除非 RCT)

考虑交叉匹配

$$\hat{z}_R(\cdot) = \operatorname{argmin}_z \left\{ \hat{\lambda}_n(z(\cdot)) + \lambda_n(z(\cdot)) \right\}.$$

$$\rightarrow \hat{\lambda}_n(z(\cdot)) = \frac{1}{n} \sum_{i=1}^n \left((Y_i - \hat{m}^{(-k(i))}(X_i)) - (w_i - \hat{e}^{(-k(i))}(X_i)) z(X_i) \right)^2$$

lasso: $\hat{z}(x) = x \cdot \hat{\beta}$ with:

$$\hat{\beta} = \operatorname{argmin}_{\beta} \left\{ \frac{1}{n} \sum_{i=1}^n \left((Y_i - \hat{m}^{(-k(i))}(X_i)) - (w_i - \hat{e}^{(-k(i))}(X_i)) x_i \beta \right)^2 + \lambda \|\beta\|_1 \right\}$$

对 $z(\cdot)$ 函数复杂性的
正则化

是 lasso 或相关归一化

PS: CNN

为什么传统IPW方法不适用？

之前假设：

$$\{Y_i(0), Y_i(1)\} \perp\!\!\!\perp w_i | Z_i \quad \text{unconfoundedness.}$$

$$\gamma \leq P\{w_i=1 | Z_i\} \leq 1-\gamma \quad \text{overlap.} \Rightarrow$$

在RD中，unconfoundedness 成立，而 overlap 不成立 $P\{w_i=1 | Z_i=z\}$ is 0 or 1;

所以只要涉及 $P\{w_i=1 | Z_i=z\}$ 都不成立

我们需要比较在 C 附近的 Z_i ，相似但不连贯：

overlap 失效 \Rightarrow 不能对 Z_C 进行 $n^{-1/2}$ 估计， Z_C 的最小最大误差
将以差参数速率递减，具体速率取决于条件响应
函数 $\mu_{w_i}(z)$ 的平滑程度：

例：

if $\mu_{w_i}(z)$ 在 C 有一个均匀有界的二阶导
则可以实现 $n^{-2/5}$ 的收敛率
 $\rightarrow v$

Lecture 5 Regression Discontinuity Designs

回归不连续设计 (临界值)

引入断点的符号:

运行变量 $Z_i \in R$: $W_i = 1(\{Z_i \geq c\})$ c 为阈值

当 $Z_i \rightarrow c$, c 邻域的样本特征相似, 仅有干预与否不同

$$\text{令 } \mu(w)(z) = E[Y_i|w)|Z_i]$$

若 $\mu(0)(z)$ 与 $\mu(1)(z)$ 连续, 定义 CATE: at $z=c$ $\tau_c = \mu(1)(c) - \mu(0)(c)$

via:

$$\tau_c = \lim_{z \rightarrow c^+} E[Y_i|Z_i=z] - \lim_{z \rightarrow c^-} E[Y_i|Z_i=z]$$

Estimation via local linear regression 局部线性回归

取较小的带宽 $h_n \rightarrow 0$; 一个对称的加权函数 $K(\cdot)$, 手入 $\mu(w)(z)$

$$\hat{\tau}_c = \operatorname{argmin} \left\{ \sum_{i=1}^n K\left(\frac{|Z_i - c|}{h_n}\right) \times (Y_i - a - z W_i - \hat{\beta}_{00}(Z_i - c) - \hat{\beta}_{11}(Z_i - c)_+)^2 \right\}$$

截距 a ; 斜率参数 $\hat{\beta}_{11}(w)$ 为干扰参数.

PS: 常用的加权函数:

窗函数 $K(x) = 1(\{|x| \leq 1\})$ window function

三角核 $K(x) = (1 - |x|)_+$ triangle kernel

$$\hat{z}_c = \operatorname{argmin} \left\{ \sum_{i=1}^n K \left(\frac{|z_i - c|}{h_n} \right) \times (y_i - a - z w_i - \beta^{(0)} (z_i - c)_- - \beta^{(1)} (z_i - c)_+)^2 \right\}$$

估计器性质

说明： $\mu^{(0)}(z)$ 和 $\mu^{(1)}(z)$ 的连续性假设，量化平滑度： $\mu(w)(z)$ 两次可微

二次导均匀有界：

$$\left| \frac{d^2}{dz^2} \mu(w)(z) \right| \leq B \quad \text{for all } z \in R \text{ and } w \in \{0, 1\}$$

若连续性较差，仅有 Lipschitz 连续（有界不可微），局部平均可能更好，因为函数在局部无明显线性趋势

若连续性更好， $k \geq 3$ 阶导也有界，用更高阶的局部回归有利于改善收敛速度

在连续性假设下，估计器的误差：

Taylor expansion: $\mu(w)(z)$ 在 c 处展开

$$\mu(w)(z) = a(w) + \beta(w)(z - c) + \frac{1}{2} \rho(w)(z - c) \quad |\rho(w)(x)| \leq B \frac{x^2}{z - c}$$

误差项.

while noting that $z_c = a^{(1)} - a^{(0)}$

\hat{z}_c (5.4) 可分为处理样本和对照样本的回归：

$$\hat{a}^{(1)}, \hat{\beta}^{(1)} = \operatorname{argmin}_{a, \beta} \left\{ \sum_{z_i \geq c} K \left(\frac{|z_i - c|}{h_n} \right) (y_i - a - \beta(z_i - c))^2 \right\}$$

同 $\hat{a}^{(0)}, \hat{\beta}^{(0)}$ $\Rightarrow \hat{z} = \hat{a}^{(1)} - \hat{a}^{(0)}$

$\hat{a}_{(1)}$ 的闭合解

之后讨论，窗函数 $k(x) = 1 \quad (\{|x| \leq 1\})$ 下：

$$\hat{a}_{(1)} = \sum_{c \leq z_i \leq c+hn} r_i p_i, \quad r_i = \frac{\hat{E}_{(1)}[(z_i - c)^2] - \hat{E}_{(1)}[z_i - c] \cdot (z_i - c)}{\hat{E}_{(1)}[(z_i - c)^2] - \hat{E}_{(1)}[z_i - c]^2}$$

where. $\hat{E}_{(1)}[z_i - c] = \sum_{c \leq z_i \leq c+hn} (z_i - c) / |\{i : c \leq z_i \leq c+hn\}|$
在带内的 \bar{y}

也可得出： $\sum_{c \leq z_i \leq c+hn} r_i = 1 \quad \text{and} \quad \sum_{c \leq z_i \leq c+hn} r_i(z_i - c) = 0$

↓

$$\hat{a}_{(1)} = a_{(1)} + \underbrace{\sum_{c \leq z_i \leq c+hn} r_i p_{(1)}(z_i - c)}_{\text{curvature bias}} + \underbrace{\sum_{c \leq z_i \leq c+hn} r_i (Y_i - \mu_{(1)}(z_i))}_{\text{sampling noise}}$$

$\hat{a}_{(1)}$ 类似、

曲率偏差

抽样噪声

需要约束二者：

1. 曲率偏差：受 Bhn^2 的上界约束， B 为关于 $\mu_{(1)}(z)$ 的二阶导的界， hn 为带宽

2. 抽样噪声：均值为 0，在 $\text{Var}[Y_i | z_i] \leq \delta^2$ 的假设下，

其方差可被约束至 $6^2 \sum_{c \leq z_i \leq c+hn} r_i^2$

若 z_i 在区的一个邻域内具有连续的，非零密度函数 $f(z)$

②)

$$6^2 \sum_{c \leq z_i \leq c+hn} r_i^2 \approx \frac{48^2}{|\{i : c \leq z_i \leq c+hn\}|} \approx \frac{48^2}{f(c)} \frac{1}{nhn}$$

若有 KP 导平滑
 $hn \sim n^{-1/2k+1}$

偏差 $\sim hn^4$ ，方差 $\sim hn^2$

↓

$$\hat{\tau}_C = \tau_C + O_p(n^{-1/5}) \quad \text{with} \quad hn \sim n^{-1/5}$$

标准误差

← 可能名可能不名

运行变量噪声 (Z_i)

$u_i \sim G$

定义两个条件: (1) Z_i 噪声: $Z_i | u_i \sim N(0, v^2)$, $v > 0$

(2) Z_i unconfounded: $\{Y_{i(0)}, Y_{i(1)}\} \perp\!\!\!\perp Z_i | u_i$

$$Y_i = Y_i(w_i) \quad \text{with } \{Y_{i(0)}, Y_{i(1)}\} \perp\!\!\!\perp w_i | u_i$$

$$e(u) := P[W_i=1|u_i] = P[Z_i \geq c|u_i] = 1 - \Phi\left(\frac{c-u_i}{v}\right)$$

$$\delta(w_i|u) := E[Y_i|w_i|u_i=u] \quad \tau(u) = E[Y_{i(1)} - Y_{i(0)}|u_i=u]$$

u_i 观测不到, 无法靠倾向得分

高斯正态分布 $\Phi(x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-\frac{t^2}{2}} dt$

一种去卷积 deconvolution 类型的估计器:

设置: $\hat{\gamma}_r = \frac{1}{n} \sum_{\{i: Z_i \geq c\}} r_+(Z_i) Y_i - \frac{1}{n} \sum_{\{i: Z_i < c\}} r_-(Z_i) Y_i$

并使加权函数商为:

$$E[\mathbb{I}\{Z_i \geq c\} r_+(Z_i)] = E[\mathbb{I}\{Z_i < c\} r_-(Z_i)] = 1$$

则可以验证:

$$E[\hat{\gamma}_r] = \underbrace{\int h_+(u) z(u) dG(u)}_{\text{加权处理效应}} + \underbrace{\int (h_+(u) - h_-(u)) \alpha_{(10)}(u) dG(u)}_{\text{混杂偏见}}$$

$$\underline{h_+(u)} = \int_c^\infty r_+(z) \varphi_V(z-u) dz \quad h_-(u) = \int_{-\infty}^c r_-(z) \varphi_V(z-u) dz$$

加权函数

$$\varphi_V(z-u) = \frac{1}{\sqrt{2\pi} v^2} e^{-\frac{1}{2} \left(\frac{z-u}{v}\right)^2}$$

正态

No.

Date

5

10

15

所以，在 $|\mu_{(W)}(z)| \leq B$ ，已知 $|z_1, \dots, z_n|$ 时：

minimax linear estimator:

$$\hat{\gamma}_c(\gamma^B) = \sum_{i=1}^n \gamma_i^B y_i,$$

$$\gamma^B = \operatorname{argmin} \left\{ \beta^2 \|\gamma\|_2^2 + I_B^2(\gamma) \right\}$$

对称局部线性估计
在 $I_B(\gamma) = 0$ 成立下

MSE 较小，更好

Lecture 6. Finite Sample Inference in RDDs

有限样本 RDD: Z_i 不连续, 或 截断函数更复杂

RDD 使用线性回归的性质:

$$\hat{\tau}_c = \operatorname{argmin} \left\{ \sum_{i=1}^n K\left(\frac{|Z_i - c|}{h_n}\right) \times (Y_i - \alpha - \tau W_i - \beta_{(0)}(Z_i - c)_+ - \beta_{(1)}(Z_i - c)_-)^2 \right\} \quad (6.2)$$

$$\hat{\tau}_c(r) = \sum_{i=1}^n \gamma_i Y_i \quad (6.3) \quad \text{6.2 的角早可写为 6.3}$$

6.3 性质为线性估计器的性质



$$Y_i(w) = \mu_{iw}(Z_i) + \varepsilon_i(w), \quad \varepsilon_i(w) | Z_i \sim N(0, b^2); \quad \text{且 } \gamma_i \text{ 仅为 } Z_i \text{ 的函数}$$

$$\text{有 } \hat{\tau}_c(r) | \{Z_1, \dots, Z_n\} \sim N(\hat{\tau}_c^*(r), b^2 \|r\|_2^2) \quad \|r\|_2 \text{ 2-范数}$$

$$\hat{\tau}_c^*(r) = \sum_{i=1}^n \gamma_i \mu_{wi}(Z_i) \quad \text{其中 } w_i = I(Z_i \geq c) \quad r = \{\gamma_1, \dots, \gamma_n\}$$

$$\|r\|_2 = \sqrt{r_1^2 + \dots + r_n^2}$$

Minimax linear estimation: 最小化最坏情况下的MSE

任何线性估计器的条件方差可以直接受观察到 $b^2 \|r\|_2^2$ (同方差误差)

而其 Bias, 依赖于未知函数 $\mu_{iw}(Z)$, 无法观察:

$$\text{Bias}(\hat{\tau}_c(r) | \{Z_1, \dots, Z_n\}) = \sum_{i=1}^n \gamma_i \mu_{wi}(Z_i) - (\mu_{(0)}(c) - \mu_{(1)}(c))$$

但当 $\mu_{iw}(Z)$ 平滑的假定下, 其仍可被界定: $|\mu_{iw}(Z)| \leq B$

即:

$$\text{Bias}(\hat{\tau}_c(r) | \{Z_1, \dots, Z_n\}) \leq I_B(r)$$

$$I_B(r) = \sup \left\{ \sum_{i=1}^n \gamma_i \mu_{wi}(Z_i) - (\mu_{(0)}(c) - \mu_{(1)}(c)) : |\mu_{iw}(Z)| \leq B \right\}$$

\sup 内不带 ABS.

$$\text{MSE}(\hat{\tau}_c(r) | \{Z_1, \dots, Z_n\}) \leq b^2 \|r\|_2^2 + I_B^2(r)$$

均方误差 = 方差 + 偏差² 与 μ 无关

二阶导在零点附近
对称



注： 最优解 $f_c(\delta) = \sum_{i=1}^n \delta_i Y_i$

$Y=1$

$Y=0$

δ_i 为差，即： $f_c(\delta) = \sum \delta^{(1)} Y_i + \sum \delta^{(2)} Y_i$



$\delta^{(1)}$ 部

和为1的权



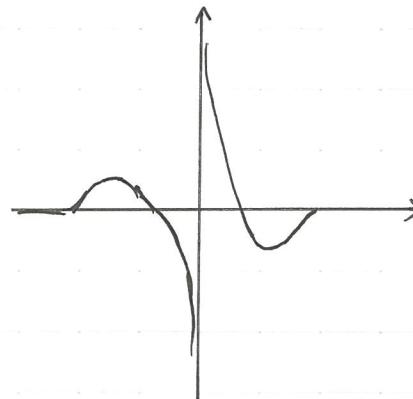
$\delta^{(2)}$ 部

和为-1权

故有： $\sum \delta_i = 1 + (-1) = 0$

$$\sum \delta^{(1)} = \sum Y_i w_i = 1$$

$$\sum \delta^{(2)} = \sum \delta_i (1 - w_i) = -1$$



$$|\mu''(w)(z)| \leq B, \text{ 已知 } z_1, \dots, z_n$$

No. _____

$$\text{minimax} : \hat{\pi}_c(\gamma^B) = \sum_{i=1}^n \gamma_i^B Y_i, \quad \gamma^B = \operatorname{argmin}_{\gamma} \{ b^2 \|\gamma\|_2^2 + I_B^2(\gamma) \} \quad (6.8)$$

Deriving the minimax linear weights

求解 6.8 中的 γ^B

$$M(w)(z) = \alpha(w) + \beta(w)(z - c) + \rho(w)(z)$$

其中 $\rho(w)(z)$ 为一个函数: $\rho(w)(c) = \rho'(w)(c) = 0$

其二阶导受 B 限制

$\alpha(w), \beta(w)$ 不受限制, 可使 $I_B(\gamma) \rightarrow \infty$; 除非加入限制:

$$\sum_{i=1}^n \gamma_i w_i = 1 \quad \sum_{i=1}^n \gamma_i = 0 \quad \sum_{i=1}^n \gamma_i (z_i - c)_+ = 0 \quad \sum_{i=1}^n \gamma_i (z_i - c)_- = 0$$

接下来只带限制 $\rho(w)(z)$: 重写 6.8:

方差 偏差

$$\{\gamma^B, t\} = \operatorname{argmin} \{ b^2 \|\gamma\|_2^2 + B^2 t^2 \}$$

$$\text{subject to: } \sum_{i=1}^n \gamma_i w_i \rho(w)(z_i) + \sum_{i=1}^n \gamma_i (1-w_i) \rho_0(z_i) \leq t$$

for all $\rho(w)(\cdot)$ with $\rho(w)(c) = \rho'(w)(c) = 0$

$$\sum_{i=1}^n \gamma_i w_i = 1 \quad \sum_{i=1}^n \gamma_i = 0 \quad \text{and } |\rho''(w)(z)| \leq 1$$

$$\sum_{i=1}^n \gamma_i w_i (z_i - c) = 0 \quad \sum_{i=1}^n \gamma_i (1-w_i) (z_i - c) = 0$$

→ 化对偶问题求解

(6.10)

Inference with linear estimators

构造 $\hat{\tau}_c(\delta^B)$ 的置信区间

$$\text{err} := \hat{\tau}_c - \tau_c$$

$$\text{err} | \{z_1, \dots, z_n\} \sim N(\text{bias}, \delta^2 \|\delta^B\|_2^2).$$

同时在 (6.10) 中 $|\text{bias}| \leq Bt$

又 Gaussian 分布是单峰的：

$$P[|\text{err}| \geq \zeta] \leq P[|Bt + b| \|\delta^B\|_2 S | \geq \zeta] \quad S \sim N(0, 1)$$

↓

level- α 置信区间：

$$P[\tau_c \in I_\alpha | \{z_1, \dots, z_n\}] \geq 1-\alpha$$

$$I_\alpha = (\hat{\tau}_c(\delta^B) - \zeta_\alpha^B, \hat{\tau}_c(\delta^B) + \zeta_\alpha^B)$$

$$\zeta_\alpha^B = \inf \{ \zeta : P[|Bt + b| \|\delta^B\|_2 S | \geq \zeta] \leq \alpha, S \sim N(0, 1) \}$$

在云上有条件：对任何分布的运行变量成立，
(6.13)

\Rightarrow 非标准设置中的回归不连续性

Example: Discrete running variable 离散运行变量 Z_i

τ_c 仅通过 $|u''_{\text{inv}}(Z)| \leq B$ 无法确定，但 (6.13) 仍有效

注：当 Z_i 连续，(6.13) 以 $n^{-1/2}$ 渐近缩小

Z_i 离散，置信区间长度不会 $\rightarrow 0$

当 Z 不在运行变量的支持范围内时，

需要一个插值函数代表 $u''_{\text{inv}}(Z)$

且 st. $|u''_{\text{inv}}(Z)| \leq B$.

Example: Multivariate running variable 多元运行变量 2/3 测试 or 地理边界 ...

RDD 以 c 为阈，用不了 (也有人换为一维距离 p ，但丢失信息)

而 minimax 可以直接拓展为多元，

Beyond homoskedasticity

异方差性不成立时

$$\rightarrow \varepsilon_i = Y_i - \mu(w_i)(z_i) \sim \text{Gaussian}$$

当异方差不成立：

$$\text{var} = \beta^2.$$

$$\text{err} | \{z_1, \dots, z_n\} \sim N(\text{bias}, \beta^2 \| \gamma \|_2^2) \quad (6.11) \text{ 不成立}$$

则：需用中心极限定理证明：

$$\hat{\pi}_c(\gamma) | \{z_1, \dots, z_n\} \approx N\left(\hat{\pi}_c^*(\gamma), \sum_{i=1}^n \gamma_i^2 \text{Var}[Y_i | z_i, w_i]\right) \quad (6.14)$$

高斯有效近似后，置信区间仍可算。

$$\text{估计条件方差 (6.14)} : \quad \hat{V}_n = \sum_{i=1}^n \gamma_i^2 (\gamma_i - \hat{\mu}(w_i)(z_i))^2$$

局部线性回归所得，

若 $\hat{\mu}(w_i)(z_i)$ 是错的，该界过于保守。
 \downarrow
 或差膨胀

$$\text{之前的 6.8} \quad \hat{\pi}_c(\gamma^B) = \sum_{i=1}^n \gamma_i^B Y_i, \quad \gamma^B = \arg \min \left\{ \beta^2 \| \gamma \|_2^2 + L_B(\gamma) \right\}$$

在同方差下 minimax

若在异方差下，而在 6.10 引入 β_i^2 (对偶的那个)

Balance
 $\hat{e}(x)$ 设计原则 }

应用 1：改进 $\hat{e}(x)$ ，损失函数

No.

Date

2: 高维 ATE 指导

Lecture 7 Balancing Estimators 平衡估计器

IPW, AIPW 用到了倾向性得分 $e(x)$ ，本 Lecture 用凸优化寻出如何估计 $e(x)$

Review:

IID samples: $\{(x_i, y_i, w_i)\} \subset X \times R \times \{0, 1\}$

goal: estimate $\tau = \mu(1) - \mu(0)$, where $\mu(w) = E[Y_i|w]$

Unconfoundedness: $\{Y_i(0), Y_i(1)\} \perp\!\!\!\perp w_i | x_i$ (7.1)

Overlap: $0 < y \leq e(x_i) \leq 1 - y < 1$ (7.2)

where $e(x) = P[w_i=1 | x_i=x]$

y 为正常数



估计 $\mu(1)$: IPW:

$$\hat{\mu}_{IPW}(1) = \frac{1}{n} \sum_{i=1}^n \frac{w_i y_i}{\hat{e}(x_i)} \quad (7.3)$$

下证 IPW 的连续性: (简要, 不严谨)

1. Population balance: unconfoundedness 下, $\mu(1) = E\left[\frac{w_i y_i}{e(x_i)}\right]$

2. oracle estimator: 当 $e(x)$ 为真下, $\hat{\mu}_{IPW}(1)$ 无偏
overlap 下, $\hat{\mu}_{IPW}(1)$ 方差有界

3. Feasible approximation: Cauchy-Schwartz 不等式 $|a-b|^2 \leq \|a\|^2 \cdot \|b\|^2$

若 $\hat{e}(x_i)$ 满足 overlap:

$$|\hat{\mu}_{IPW}(1) - \hat{\mu}_{IPW}^*(1)| \leq \sqrt{\frac{1}{n} \sum_{i=1}^n \left(\frac{1}{\hat{e}(x_i)} - \frac{1}{e(x_i)}\right)^2} \sqrt{\frac{1}{n} \sum_{i=1}^n (w_i y_i)^2}$$

$$\leq \frac{1}{y^2} \sqrt{\frac{1}{n} \sum_{i=1}^n (\hat{e}(x_i) - e(x_i))^2} \sqrt{\frac{1}{n} \sum_{i=1}^n (w_i y_i)^2} \quad (7.4)$$

在 AIPW 中, $n \rightarrow \infty$, 7.4 的误差相较于 $1/\sqrt{n}$ 为一个极小项

Population vs. sample balance

将条件响应函数用基础函数展开 basis expansion.

$$\mu_{\text{pop}}(x) = \sum_{j=1}^{\infty} \beta_j(w) \psi_j(x) \quad \leftarrow \text{基础函数 (多项式基、傅里叶基, ...)}$$

其中 $\psi_j(\cdot)$ 是一组预定义的基础函数

在合理的正则性条件下: 有

? 连续可积且平滑
 $\mu(w) = \sum_{j=1}^{\infty} \beta_j(w) E[\psi_j(x_i)] \quad (\text{左右求 } E)$

揭示性证, IPW 在总体 population 上有效:

已有 | uncondon dedness 无混杂性.

$$E\left[\frac{w_i y_i}{e(x_i)}\right] = E\left[\frac{w_i}{e(x_i)} \sum_{j=1}^{\infty} \beta_j(w) \psi_j(x_i)\right]$$

$$E[\varepsilon_i | x_i, w_i] = 0$$

$$\begin{aligned} &= \sum_{j=1}^{\infty} \beta_j(w) E\left[\frac{w_i \psi_j(x_i)}{e(x_i)}\right] \quad \overset{w_i=1}{\Downarrow} \quad E[w_i | x_i] = e(x_i) \\ &= \sum_{j=1}^{\infty} \beta_j(w) \underbrace{E[\psi_j(x_i)]}_{\leftarrow \text{本质}} = \mu(w) \end{aligned}$$

所以, 我们在选择权重的时候:

$$\frac{1}{n} \sum_{i=1}^n \frac{w_i \psi_j(x_i)}{e(x_i)} \approx \frac{1}{n} \sum_{i=1}^n \psi_j(x_i), \text{ for all } j=1, 2, \dots$$

(7.8)

No.

Date

5

10

15

范数： $\|\cdot\|_0$ 范数， $\sum (x_i)^0$

$\|\cdot\|_1$ 范数， $\sum |x_i|$

$\|\cdot\|_2$ 范数 $\sqrt{\sum x_i^2}$

$\|\cdot\|_\infty$ 范数 $\max(|x_i|)$

$$\|\cdot\|_p = \|(x_i)\|_p = \sqrt[p]{\sum_{i=1}^n |x_i|^p}$$

$$\frac{1}{n} \sum_{i=1}^n \frac{w_i \psi_j(x_i)}{\hat{e}(x_i)} \approx \frac{1}{n} \sum_{i=1}^n \psi_j(x_i) \text{, for all } j=1, 2, \dots$$

(7.8)

No.

Date

① Balancing loss function for propensity estimation

假设，有一个线性的结果模型：

$$\mu(w)(x) = x \cdot \beta(w)$$

实现样本平衡仅涉及到

一个 logistic 倾向模型：

$$e(x) = 1 / (1 + e^{-x\theta})$$

平衡协变量 x_i

改写 7.8.

$$\frac{1}{n} \sum_{i=1}^n (1 + e^{-x_i \theta}) w_i x_i = \frac{1}{n} \sum_{i=1}^n x_i$$

更好的平衡，(仅限低值)



(7.9)

#

7.9 为以下凸问题的 KKT 条件： → 因此可用一个 Newton descent 导出唯一解

$$\hat{\theta} = \operatorname{argmin}_{\theta} \left\{ \frac{1}{n} \sum_{i=1}^n l_{\theta}(x_i, y_i, w_i) \right\}$$

$$l_{\theta}(x_i, y_i, w_i) = w_i e^{-x_i \theta} + (1-w_i)x_i \theta \quad (7.10)$$

作为损失函数更好。

P+类

不同
估计 $\mu(w_0), \mu(w_1)$ 行用 2 个倾向
模型

②

ATE estimation with high-dimensional confounders

用高维混杂变量处理 ATE

例 $x_i \in \mathbb{R}^P$ 可能 $P \gg n$

而 $\mu(w)(x) = x \cdot \beta(w)$ 对某个 $\beta(w) \in \mathbb{R}^P$ 高维情况下，有足够的稳定的 $\beta(w)$ 很
找精准权重不可能，只求近似平衡：

Hölder 不等式：

$$\left| \frac{1}{n} \sum_{i=1}^n \frac{w_i \mu_{(1)}(x_i)}{e(x_i)} - \frac{1}{n} \sum_{i=1}^n \mu_{(1)}(x_i) \right| \leq \left(\sum_{i=1}^n |a_i b_i|^p \right)^{1/p} \left(\sum_{i=1}^n |b_i|^q \right)^{1/q}$$

$$= \left| \left(\frac{1}{n} \sum_{i=1}^n \frac{w_i x_i}{e(x_i)} - \frac{1}{n} \sum_{i=1}^n x_i \right) \beta_{(1)} \right| \leq \left\| \frac{1}{n} \sum_{i=1}^n \frac{w_i x_i}{e(x_i)} - \frac{1}{n} \sum_{i=1}^n x_i \right\|_{\infty} \|\beta_{(1)}\|_1 \quad (7.11)$$

? ⇒ 暗示：好的逆倾向性权重应使平衡程度最差的情况下最好 不平衡度

problems : ① 如何参数化 $\hat{e}(x_i)$ ，以实现 7.11 supnorm approximate balance
② 上述界限只有在 $\|\beta_{(1)}\|_1$ 有界时才有意义

高维统计中，通常设 $\beta_{(1)}$ 应稀疏，
却未限制其范数

#

对于某个 well chosen ζ :

$$\hat{\gamma} = \operatorname{argmin}_{\gamma} \left\{ \underbrace{\frac{1}{n^2} \|\gamma\|_2^2}_{L_2 \text{范数}} + \zeta \left\| \underbrace{\frac{1}{n} \sum_{i=1}^n (\gamma_i w_i - 1) x_i}_{\text{不平衡度}} \right\|_\infty^2 : \gamma_i \geq 1 \right\} \quad (7.12)$$

之后，使用 $y_{\hat{e}(x_i)} = \hat{r}_i$ 作为逆倾向性加权

用 sub-Gaussian concentration inequalities 验证 $e(x)$ 满足：

$$\frac{1}{n^2} \left\| \frac{1}{e(x_i)} \right\|_2^2 \leq \frac{1}{n} \quad , \quad \left\| \frac{1}{n} \sum_{i=1}^n (\gamma_i w_i - 1) x_i \right\|_\infty^2 = O_p \left(\frac{\log(p)}{n} \right) \quad (7.13)$$

这里 $\hat{e}(x_i)$ 可能不是 $e(x)$ 的好估计，但 $y_{\hat{e}(x)} = \hat{r}_i$ 在 ζ 好的情况下满足缩放界限

二、用高维回归增强加权估计器，解决对 $\|\beta^{(1)}\|_1$ 的依赖

增强平衡估计器：

$$\hat{\mu}_{AB}^{(1)} = \frac{1}{n} \sum_{i=1}^n \hat{\mu}_{ij}^{(1)}(x_i) + \hat{r}_i w_i (y_i - \hat{\mu}_{ij}^{(1)}(x_i)) \quad , \quad \hat{\mu}_{ij}^{(1)}(x_i) = x_i \hat{\beta}^{(1)} \quad (7.14)$$

$$\begin{aligned} \hat{\mu}_{AB}^{(1)} &= \underbrace{\frac{1}{n} \sum_{i=1}^n x_i \hat{\beta}^{(1)}}_{\text{均: } \mu_{ij}^{(1)}(x_i)} + \underbrace{\frac{1}{n} \sum_{i=1}^n \hat{r}_i w_i (y_i - x_i \hat{\beta}^{(1)})}_{\text{noise, mean-0}} \\ &\quad + \underbrace{\left(\frac{1}{n} (1 - \hat{r}_i w_i) x_i \right) (\hat{\beta}^{(1)} - \beta^{(1)})}_{\text{偏差}} \end{aligned} \quad (7.15)$$

\hat{r}_i 只纠正 $\beta^{(1)} - \hat{\beta}^{(1)}$ ，而非 $\beta^{(1)}$

而在高维回归中，我们知道如何获取 $\|\beta^{(1)} - \hat{\beta}^{(1)}\|_1$ 的强界限

尤其在稀疏性 $\|\beta^{(1)}\|_0 \leq k$ 和受限特征条件下，lasso 可以实现 1-范数误差

即

$$\|\hat{\beta}^{(1)} - \beta^{(1)}\|_1 = O_p \left(k \sqrt{\frac{\log(p)}{n}} \right)$$

整合：

(7.16)

X_i 满足 $\|\hat{\beta}_{(1)} - \beta_{(1)}\|_1 = O_p(k \sqrt{\frac{\log(p)}{n}})$ 成立的条件.

$\beta_{(1)}$ 是 k -sparse (k稀疏) , $k \ll \sqrt{n} / \log(p)$

Then:

① 在 treated units 上运行 lasso 回归

\Rightarrow find $\beta_{(1)}$ 的 1-范数误差减为 $O_p(1/\sqrt{\log(p)})$

② 用 (7.12) 拟合 \hat{Y} , 其中无穷范数的不平行为 $O_p(\sqrt{\log(p)/n})$

③ 用 (7.14) 估计 $\mu_{AB(1)}$, 将两个界限代入 (7.15)

$$\hat{\mu}_{AB(1)} - \underbrace{\frac{1}{n} \sum_{i=1}^n X_i \beta_{(1)}}_{\mu_{AB}(X_i) \text{ mean}} = \underbrace{\frac{1}{n} \sum_{i=1}^n \hat{r}_i w_i (Y_i - X_i \beta_{(1)})}_{\text{noise} \sim O_p(1/\sqrt{n})} + O_p(\frac{1}{\sqrt{n}}) \quad (7.17)$$

也有中心极限:

$$\frac{\sum_{i=1}^n \hat{r}_i w_i (Y_i - X_i \beta_{(1)})}{\sqrt{\sum_{i=1}^n \hat{r}_i^2 w_i^2 (Y_i - X_i \beta_{(1)})^2}} \Rightarrow N(0, 1)$$

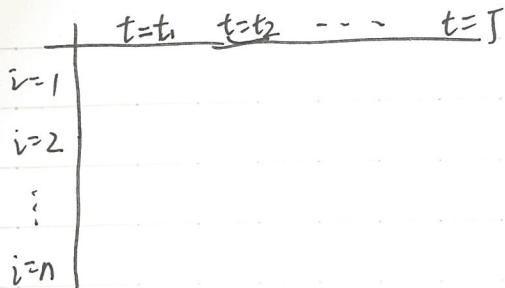
比预期弱, 因为我们只用了 $\mu_{AB}(X_i)$ 样本平均值的置信区间, $\bar{\mu}_{(1)} := n^{-1} \sum_{i=1}^n X_i \beta_{(1)}$

而不是 $\mu_{(1)}$ 本身

要得到关于 $\mu_{(1)}$ 的结果, 需要展示 \hat{r}_i 的收敛性

No.

Date



附，若对 ϵ_{it} 建模：视行间噪声 IID. 即 $\text{Var}[\epsilon_{it}] = \Sigma$
 (将每个 ϵ_{it} 视为独立难以证明且不合理)

当 $T=2$:

$$\text{直接考虑差异的方差: } \widehat{\text{Var}}[\widehat{\epsilon}_t] = \frac{\widehat{\text{Var}}[Y_{i2} - Y_{i1} | W_{i2}=1]}{| \{i: W_{i2}=1\} |} + \frac{\widehat{\text{Var}}[Y_{i2} - Y_{i1} | W_{i2}=0]}{| \{i: W_{i2}=0\} |} \quad (8.4)$$

该式在 ϵ_{it} 行内相关时，也 Robust

Lecture 8 Methods for Panel Data 面板数据

面板数据(纵向数据)

$i=1, \dots, n$ 个单位，在 $t=1, \dots, T$ 个时间段的数据

A constant treatment effect model 常量 治疗效应

结果: $Y_{it} \in \mathbb{R}$; 治疗分配: $W_{it} \in \{0, 1\}$

$$Y_{it} = Y_{it}(0) + W_{it} \tau, \quad \text{for all } i=1, \dots, n, t=1, \dots, T \quad (8.1)$$

PS: 这是最基础的模型，
其未考虑 { treatment heterogeneity 治疗异质性: 治疗在所有 t 内以相同方式影响所有之
治疗与时间无关 与时间相关 治疗通过
治疗 dynamics 治疗动态性: 单位 i 在 t 的结果仅受
治疗与 t 前无关 其在 t 接受的治疗影响

The two-way model

$$Y_{it} = \alpha_i + \beta_t + W_{it} \tau + \varepsilon_{it}, \quad E[\varepsilon | \alpha, \beta, w] = 0 \quad (8.2)$$

单位和时间上的偏移

治疗严格外生, 强正态偏倚性

如:

$$i \in N_1 \quad W_i = (0, 0)$$

$$i \in N_2 \quad W_i = (0, 1)$$

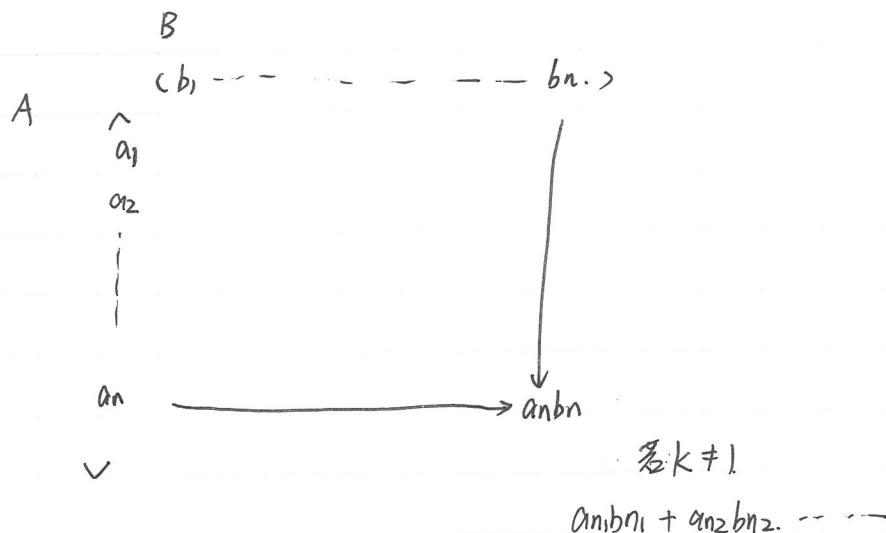
$$\hat{\tau} = \frac{1}{| \{i : W_{i2}=1\} |} \cdot \sum_{i: W_{i2}=1} (Y_{i2} - Y_{i1}) - \frac{1}{| \{i : W_{i2}=0\} |} \sum_{i: W_{i2}=0} (Y_{i2} - Y_{i1})$$

(DID法)

缺: 在 n, T 很大, 且 W_{it} 有通用分布下, (8.2) 不适合;

类似地, 只有 2 个时间段, 用 OLS 处理出的有时也称为 DID, (但 OLS 无闭合解)

优: 平行趋势 (单位仅由 α_i 不同), 下很直观, 无平行则不可用



PS:

合成控制并非处理交互式固定效应的唯一方法：

例：

通过 k -均值聚类矩阵 Y 的行，然后分别为每个群组
拟合时变基浅模型 P66. 文献

Interactive panel models

交互式面板模型

$$Y_{it} = A_i \cdot B_t + W_{it} \tau + \varepsilon_{it}, \quad E[\varepsilon | A, B, W] = 0, \quad A \in R^{n \times k}, \quad B \in R^{r \times k} \quad (8.5)$$

其中 k 是某个秩参数

Equivalently:

$$Y_{it} = L_{it} + W_{it}Z + \varepsilon_{it} \quad \text{for some rank-}k \text{ matrix } L$$

处理该模型：合成控制 and 合成差分

设，当且仅当 $i > n_0$ 且 $t > T_0$ ： $W_{it} = 1$

$$\sum_{i=1}^{n_0} y_i Y_{it} \approx \alpha + \frac{1}{n-n_0} \sum_{i=n_0+1}^n Y_{it}, \quad t=1, \dots, T.$$

去除重复 T₀后变下 又是一个类似于固定效应
相似的参数

其中 α 的选择：

$$r = \underset{\gamma, d}{\operatorname{argmin}} \left\{ \left\| \sum_{i=1}^{n_0} \gamma_i' Y_i (1:T_0) - \frac{1}{n-n_0} \sum_{i=n_0+1}^n Y_i (1:T_0) - d \right\|_2^2 : \sum_{i=1}^{n_0} \gamma_i' = 1, \gamma_i' \geq 0 \right\} \quad (8.7)$$

\hat{y}_i 的目的是创建平行趋势，其应可平行 A_i

$$\text{最小化: } \hat{\tau} = \operatorname{argmin}_{\tau'(\alpha', \beta)} \left\{ \sum_{it} y_i (Y_{it} - d_i - \beta t - W_{it} \tau')^2 \right\}, \quad (18.8)$$

1

$$j_i = \frac{1}{n-n_0}, \text{ for } i > n_0$$

其有封闭角:

$$\hat{Y}_t = \frac{1}{n-n_0} \sum_{i=n_0+1}^n \left(\frac{1}{T-T_0} \sum_{t=T_0+1}^T Y_{it} - \frac{1}{T_0} \sum_{t=1}^{T_0} Y_{it} \right) - \sum_{i=1}^{n_0} \delta_i \left(\frac{1}{T-T_0} \sum_{t=T_0+1}^T Y_{it} - \frac{1}{T_0} \sum_{t=1}^{T_0} Y_{it} \right)$$

与 T₀ 与 n 有关

且该解,在适当的大面板渐近下 ($n_0, n_1, T \rightarrow \infty$)

并允许对低秩规范(8.5)中的

中的 1. 进行渐近正态推断

No.

Date

$$(8.2): Y_{it} = \alpha_i + \beta t + W_{it} + \varepsilon_{it}, \in [\varepsilon | \alpha, \beta, w] = 0$$

P67, [2019]

附: (8.11) $\hat{\gamma} = \sum_{it} \gamma_{it} Y_{it}$ 在 (8.2) 下也无偏

只要满足:

$$\left\{ \begin{array}{l} \sum_t \gamma_{it} = 0 \text{ for all } i = 1, \dots, n \\ \sum_i \gamma_{it} = 0 \text{ for all } t = 1, \dots, T \\ \sum_{it} \gamma_{it} W_{it} = 1 \end{array} \right.$$

三个式子消除了固定效应 α_i, β

基于此, 得一双重稳健估计器

$$\hat{\gamma} = \operatorname{argmin}_{\gamma'} \sum_{it} \gamma_{it}^2$$

subject to: $\sum_{it} \gamma_{it} W_{it} = 1, \quad \sum_{\{i: s_i = s\}} \gamma_{it} = 0 \text{ for all } s, t,$

$$\sum_i \gamma_{it} = 0 \text{ for all } i; \quad \sum_t \gamma_{it} = 0 \text{ for all } t,$$

(3) 只要 (8.2) 及 (8.10) 成立, 其无偏

$$Y_{it} = Y_{it}^{(0)} + w_{it}\gamma$$

Identification via exchangeability

"design-based" assumptions.

$$Y_{it}^{(0)} \perp\!\!\!\perp w_{it} \mid S_i, \quad S_i = \sum_{t=1}^T w_{it} \quad (8.10)$$

其中一个推论为：

例如： $\hat{\gamma} = \sum_{it} \gamma_{it} Y_{it}$ 的估计器，实现了 γ 的无偏估计。 (8.11)
其中 γ -matrix 仅依赖 w_{it}

在 (8.10) 下， $Y_{it}^{(0)}$ 可交换：

$$E[\hat{\gamma} | W, r] = \sum_{it} \gamma_{it} E[Y_{it}^{(0)} | S_i] + \sum_{it} \gamma_{it} w_{it} \quad \text{对 } \forall t, \frac{\sum_{it} \gamma_{it}}{0} \frac{E[Y_{it}^{(0)} | S_i]}{\text{constant}} = 0$$

因此，当 $\sum_{it} \gamma_{it} w_{it} = 1$ ，且

$$\sum_{\substack{i: S_i=s \\ it}} \gamma_{it} = 0 \quad \text{for all } t=1, \dots, \text{and } s \in S$$

S 表示 S_i 的支持

(8.11) 无偏

通过最小化这些无偏性约束下的方差来选择 γ ：

$$\gamma = \operatorname{argmin}_{\gamma} \left\{ \sum_{it} \gamma_{it}^2 : \sum_{it} \gamma_{it} w_{it} = 1, \sum_{it} \gamma_{it} = 0 \text{ for all } s, t \right\} \quad (8.14)$$

一般来说，只要 w_{it} 在相同 S_i 下有变化

No.

Date

Z_i 作为工具变量的三个条件：

- ① Z_i 必须是 exogenous (外生的) 且 $\text{Corr}[Z_i]$
- ② Z_i relevant $\text{Cov}[W_i, Z_i] \neq 0$
- ③ Z_i exclusion restriction 排除性限制



Z_i 对 Y_i 的所有影响必须通过 W_i



Lecture 9 Instrumental Variables Regression

工具变量回归，修正内生处理效果（有偏 $Y_{i(0)}$ 且 w_i ）

A structural model 结构模型

无偏模型：

$$Y_{i(w)} = Y_{i(0)} + w_i z, \quad Y_i = Y_{i(w_i)} \quad (9.1)$$

一般无偏指： $\{Y_{i(w)}\} \perp\!\!\!\perp w_i$ ，(9.1) 中指 $Y_{i(0)} \perp\!\!\!\perp w_i$



$$Y_i = \alpha + w_i z + \varepsilon_i \quad (9.2)$$

$$\text{where: } \alpha = E[Y_{i(0)}] \quad \varepsilon_i = Y_{i(0)} - E[Y_{i(0)}]$$

$$E[\varepsilon_i | w_i] = 0 \quad , \text{用 OLS } Y_i \sim w_i \text{ 不成立}$$



当无偏： $Y_{i(0)} \perp\!\!\!\perp w_i$ ，(9.2) 仍成立，但 $E[\varepsilon_i | w_i] \neq 0$

若 9.2 用 OLS：

$$\underbrace{\tau_{OLS}}_{\text{OLS 的估计}} = \frac{\text{Cov}[Y_i, w_i]}{\text{Var}[w_i]} = \frac{\text{Cov}[z w_i + \varepsilon_i, w_i]}{\text{Var}[w_i]} = z + \frac{\text{Cov}[\varepsilon_i, w_i]}{\text{Var}[w_i]} \neq z$$

Identification using instrumental variables. z_i

$$Y_i = \alpha + w_i z + \varepsilon_i, \quad \varepsilon_i \perp\!\!\!\perp z_i$$

$$w_i = z_i \gamma + \eta_i \quad (9.4)$$

z_i 与 η_i 不相关：

$$\text{Cov}[Y_i, z_i] = \text{Cov}[z w_i + \varepsilon_i, z_i] = z \text{Cov}[w_i, z_i]$$

即：

$$z = \text{Cov}[Y_i, z_i] / \text{Cov}[w_i, z_i]$$

则在估计时：

$$\hat{z} = \widehat{\text{Cov}}[Y_i, z_i] / \widehat{\text{Cov}}[w_i, z_i]$$

No.

Date

可拓展为: $\mathbb{E}[Y_i | Z_i | X_i]$

$$\tau(x) = \frac{\text{Cov}[Y_1, w(Z_1) | X_1=x]}{\text{Cov}[W_1, w(Z_1) | X_1=x]} \Rightarrow$$

| 有构建平均效应 $\tau = E[\alpha x]$ 的双重稳健估计量.
| $\tau(\cdot)$ 随机森林估计量

当 X_1, X_2 独立.

$$\text{Var}(X_1, X_2) = \text{Var}(X_1)\text{Var}(X_2) + E^2(X_2)\text{Var}(X_1) + E^2(X_1)\text{Var}(X_2)$$

Optimal instruments 最优工具变量

将 z_i 拓展为至高维空间:

$$Y_i = Z W_i + \varepsilon_i, \quad \varepsilon_i \perp\!\!\! \perp z_i, \quad Y_i, W_i \in \mathbb{R}, \quad z_i \in \mathbb{Z}$$

\mathbb{Z} 是 high-dimensional space.

w为函数: $w: \mathbb{Z} \rightarrow \mathbb{R}$:

$$\tau = \frac{\text{Cov}[Y_i, w(z_i)]}{\text{Cov}[W_i, w(z_i)]} \quad (9.8)$$

必须为0

问题: $w(\cdot)$ 什么时候最优? 最优转换:

$$\hat{w}_w = \frac{\widehat{\text{Cov}}[Y_i, w(z_i)]}{\widehat{\text{Cov}}[W_i, w(z_i)]} = \frac{\frac{1}{n} \sum_{i=1}^n (Y_i - \bar{Y})(w(z_i) - \bar{w}(z))}{\frac{1}{n} \sum_{i=1}^n (W_i - \bar{W})(w(z_i) - \bar{w}(z))} \quad (9.8)$$

$$\therefore \text{with: } \bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i$$

注意到, \hat{w}_w (9.8) 的值为估计方程的解.

$$\frac{1}{n} \sum_{i=1}^n (w(z_i) - \bar{w}(z))(Y_i - \bar{Y} - \hat{w}_w(W_i - \bar{W})) = 0 \quad (9.10)$$

可推

$$n(\hat{w}_w - \tau) \Rightarrow N(0, V_w), \quad V_w = \frac{\text{Var}[\varepsilon_i] \text{Var}[w(z_i)]}{\text{Cov}[W_i, w(z_i)]^2} \quad (9.11)$$

$$\text{由于 } z_i \perp\!\!\! \perp \varepsilon_i \Rightarrow \text{Var}[\varepsilon_i(w(z_i) - E[w(z_i)])] = \text{Var}[\varepsilon_i] \text{Var}[w(z_i)]$$

$$E[\varepsilon_i] = 0$$

最优:

$$w^*(\cdot) \in \arg \min_w \left\{ \text{Cov}[W_i, w'(z_i)]^2 / \text{Var}[w'(z_i)] \right\}.$$

解为:

$$w^*(z) \propto E[W_i | z_i = z] \Rightarrow w^*(z) \text{ 是 } w_i \text{ 从 } z_i \text{ 的最佳预测}$$

★:

若对一些函数 ψ_i 满足 $E[\psi_i(\theta)] = 0$

当通过

$$\frac{1}{n} \sum_{i=1}^n \psi_i(\theta) = 0 \quad \text{去估计 } \hat{\theta},$$

由非参数 delta 方法：

一般来说： $\sqrt{n}(\hat{\theta} - \theta) \rightarrow N(0, V)$

$$\text{其中 } V = \frac{\text{Var}[\psi_i(\theta)]}{E[\psi_i(\theta)]^2}$$

Cross-fitting and feasible estimation

交叉拟合和可行估计

最优工具变量解:

$$w^*(z) = E[w_i | z_i = z]$$

一般 step: | ① 拟合一个非参数的前一阶段回归, 得 $E[w_i | z_i = z]$ 的估计 $\hat{w}(z)$
 | ② 用 $\hat{w}(z)$ 作为 IV 运行 (9.9) $\Rightarrow \hat{w}$

但当 IV 较弱时, 会有过拟合偏见:

当 $\hat{w}(z_i)$ 由训练数据拟合的, 则 $\hat{w}(z_i) \neq \varepsilon_i$: 因为 $\hat{w}(z_i) \in w_i \subset \varepsilon_i$

↓

假设 ε_i 为 noise $w_i = \alpha + \beta z_i + \varepsilon_i$

$$y_i = \delta + \gamma \hat{w}_i + \varepsilon_i$$

$$= \delta + \frac{\hat{\alpha} + \hat{\beta} z_i}{\text{偏}} + \varepsilon_i \quad (9.13)$$

$$\text{与 } Y_i = \delta + \alpha w_i + \varepsilon_i$$

矛盾

用交叉拟合:

K个折算, 对每个k:

$$\hat{\tau} = \frac{\hat{\text{cov}}[Y_i, \hat{w}^{(-k(i))}(z_i)]}{\hat{\text{cov}}[w_i, \hat{w}^{(-k(i))}(z_i)]}$$

则有: $\hat{w}^{(-k(i))}(z_i) \perp \varepsilon_i$

特别是, 当 $\hat{w}^{(-k(i))}(z)$ 在 MSE 中对 $E[w_i | z_i = z]$ 是一致的. 由 9.13-9.9 得证

↓

$$\lim_{n \rightarrow \infty} E[(\hat{w}_n - E)^2] = 0 \quad n \text{ 为样本量.}$$

Non-parametric instrumental variables regression 非参数 IV 回归

基本假设 $Y_i = W_i z + \varepsilon_i$ (即 z_i 线性作用于 Y_i)

推广:

$$Y_i = g(W_i) + \varepsilon_i \quad z_i \perp \varepsilon_i, \quad Y_i, W_i \in \mathbb{R}, \quad z_i \in \mathbb{Z}$$

$g(\cdot)$ 为一般单值函数

不能简单进行 $Y_i \sim W_i$ 非参数回归, 即 $g(\cdot) \neq E[Y_i | W_i = w]$

则应该:

$$\Rightarrow z_i \perp \varepsilon_i, \quad E[\varepsilon_i] = 0:$$

$$\begin{aligned} E[Y_i | z_i = z] &= E[g(W_i) + \varepsilon_i | z_i = z] \\ &= E[g(W_i) | z_i = z] \\ &= \int_{\mathbb{R}} g(w) f(w | z) dw \end{aligned} \tag{9.15}$$

其中 $f(w | z)$ 表示给定 $z_i = z$ 时

w_i 的条件密度

则学习方案: (1) 拟合 $f(w | z)$, 且用交叉拟合.

(2) 最小化估计 $g(w)$, 选择一个合适的函数类 G .

$$\hat{g}(\cdot) = \operatorname{argmin}_{g \in G} \left\{ \frac{1}{n} \sum_{i=1}^n (Y_i - \int_{\mathbb{R}} g(w) \hat{f}^{(-k(i))}(w | z_i) dw)^2 \right\} \tag{9.16}$$

为了在实践中解决(9.16), 一种方法是用基函数展开近似 $g(w)$, 即:

$g_k(w) = \sum_{k=1}^K \beta_k \psi_k(w)$ 其中 $\psi_k(\cdot)$ 是一组预先确定的基函数, $g_k(w)$ 随 $k \uparrow$ 更好逼近 $g(w)$.

$$\hat{\beta} = \operatorname{argmin}_{\beta} \left\{ \frac{1}{n} \sum_{i=1}^n (Y_i - \hat{m}^{(-k(i))}(z_i) \beta)^2 \right\} \tag{9.17}$$

其中 $\hat{m}^{(-k(i))}(z_i) = \int_{\mathbb{R}} \psi_k(w) \hat{f}^{(-k(i))}(w | z_i) dw$

类似 9.13

其为 $g(\cdot)$ 一致估计需要条件, (9.15) 很复杂; 用 (9.17) 而仔细近似化, 即使如此 KOKUYO
1.6.1.6 速度可快 1.7 得 1.8

4 types:

$W_i(0) = 0$	$W_i(1) = 0$	$W_i(1) = 1$
	never taker	complier 依从者
$W_i(0) = 1$	defier 反抗者	always taker

对 W_i :假设没有 defier: 单调性 monotonicity $W_i(1) \geq W_i(0)$.

$$\begin{aligned} \text{有: } & E[Y_i | Z_i=1] - E[Y_i | Z_i=0] \\ &= E[Y_i(W_i(1)) | Z_i=1] - E[Y_i(W_i(0)) | Z_i=0] \\ &= E[Y_i(W_i(1))] - E[Y_i(W_i(0))] \\ &= E[\mathbb{1}\{C_i = \text{complier}\})(Y_i(1) - Y_i(0))] \end{aligned}$$

若 compliers 一定存在, 由 Bayes' rule:

$$\tau_{\text{LATE}} = \frac{E[Y_i | Z_i=1] - E[Y_i | Z_i=0]}{E[W_i | Z_i=1] - E[W_i | Z_i=0]}$$

$$= E[Y_i(1) - Y_i(0) | C_i = \text{complier}] \quad (10.3)$$

LATE (complier average treatment)

PS: 当 (10.1) 不成立, 有 $\text{at}, \text{at}, \text{defier}$...

$$\text{IATE} = E[Y_i(1)] - E[Y_i(0)]$$

never taker 的 $W_i = 1$ $\times P_{\text{LATE}}$ 不成立

Lecture 10 Local Average Treatment Effect 局部平均处理效应

由 L 个的 IV 模型：

$$\begin{aligned} Y_i &= d + W_i \tau + \varepsilon_i \quad , \quad \varepsilon_i \perp \! \! \! \perp Z_i \\ W_i &= Z_i \gamma + \eta_i \end{aligned} \quad (10.1)$$

当 Z_i 为二元：

$$\begin{aligned} \tau &= \text{Cov}[Y_i, Z_i] / \text{Cov}[W_i, Z_i] \\ &= \frac{E[Y_i | Z_i=1] - E[Y_i | Z_i=0]}{E[W_i | Z_i=1] - E[W_i | Z_i=0]} \end{aligned} \quad (10.2)$$

Treatment effect estimation under non-compliance 非依从性

非依从：RCT 下：

实际接受治疗 分配的治疗	$\left\{ \begin{array}{l} Y_i \in R, \text{ 通常} \\ W_i \in \{0,1\} \quad \text{非随机, 因为有非依从性} \\ Z_i \in \{0,1\} \quad \text{随机} \end{array} \right.$
-----------------	--

实际上：(10.1) 中 Z 为常数也许不对， W_i 也许与 Z 相关，等。

需要定义： $\{W_{i(0)}, W_{i(1)}\} \Rightarrow W_i(Z_i)$ ， $Y_i = Y_i(W_i, Z_i)$

综上：IV 有效假设如下：

- Exclusion restriction $Y_i(w, z) = Y_i(w)$ 治疗分配仅通过接受治疗来影响结果
- Exogeneity $\{Y_{i(0)}, Y_{i(1)}, W_{i(0)}, W_{i(1)}\} \perp \! \! \! \perp Z_i$ 治疗分配是随机的
- Relevance $E[W_{i(1)} - W_{i(0)}] \neq 0$ 治疗分配影响到治疗的接受

Supply and demand. 价格 - 需求

对每个市场 $i = 1, \dots, n$, 有一个供应曲线 $S_i(p, z)$ 和一个需求曲线 $Q_i(p, z)$
价格 $p \in \mathbb{R}$, $IV: z \in \{0, 1\}$

(假设 $S_i(\cdot, z)$ 连续且单增, $Q_i(\cdot, z)$ 连续且单减)

该假设下: P_i 是 $S_i(P_i, z_i) = Q_i(P_i, z_i)$ 的唯一解

即: z_i 为 IV; P_i 为 treatment; $Q_i(P_i, z_i)$ 为 outcome (y_i)

排除限制

$z_i \rightarrow S \rightarrow P_i \rightarrow Q_i(p)$

- 约束条件:
- Exclusion restriction: $Q_i(p, z) = Q_i(p)$ for all p and z
 - Exogeneity: $\{Q_i(p), S_i(p, z)\} \perp \!\!\! \perp z_i$
 - Relevance: $Cov[P_i, z_i] \neq 0$
 - 单调: Monotonicity: $S_i(P_i, 1) \leq S_i(P_i, 0)$ 没处处成立

设 $Q_i(p)$ 可微, $Q'_i(p)$ 为其导数 (不必, 因为 $Q_i(\cdot)$ 已↑, 因此分布导数必存在)

$$\text{ZATE} = \frac{E[Q_i(p)|z_i=1] - E[Q_i(p)|z_i=0]}{E[P_i|z_i=1] - E[P_i|z_i=0]}$$

$$= \frac{\int E[Q'_i(p)|P_i(0) \leq p \leq P_i(1)] P[P_i(0) \leq p \leq P_i(1)] dp}{\int P[P_i(0) \leq p \leq P_i(1)] dp} \quad \text{川度积分}$$

推导: $E[Q_i(p)|z_i=1] - E[Q_i(p)|z_i=0]$

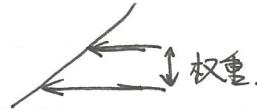
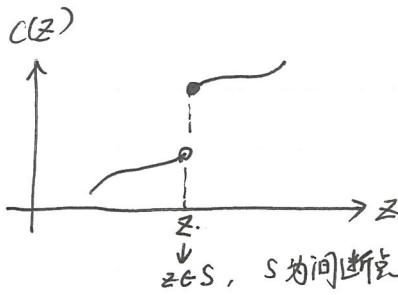
$$= E[Q_i(P_i(1))|z_i=1] - E[Q_i(P_i(0))|z_i=0]$$

对称积分次序

$$= E[Q_i(P_i(1)) - Q_i(P_i(0))]$$

Fubini 定理 ~ 夫美

$$= E \left[\int_{P_i(0)}^{P_i(1)} Q'_i(p) dp \right] = \underline{\int E[Q'_i(p)|P_i(0) \leq p \leq P_i(1)] P[P_i(0) \leq p \leq P_i(1)] dp}$$



$$(10.2) : \text{ZLATE} = \frac{E[Y_i | z_i=1] - E[Y_i | z_i=0]}{E[W_i | z_i=1] - E[W_i | z_i=0]}$$

改写为积分：

分子：

$$\sum_{z \in S} \left(\int_{c(z)}^{c(z)} zu du \right) \varphi(z) + \int_{R \setminus S} \frac{u(c(z)) c'(z)}{\downarrow} \varphi(z) dz$$

$\xrightarrow{\text{权重}}$

$c(z)$ \uparrow
 $c(z)$ \downarrow
 u .

zu \downarrow
 du 权重

$z \in S$ 的概率
 \uparrow

$u = c(z)$ 处理期望
 \downarrow 权重

分母：

$$\sum_{z \in S} (c(z) - c(-z)) \varphi(z) + \int_{R \setminus S} c'(z) \varphi(z) dz \quad \text{总权}$$

Threshold crossing and willingness to pay 阈值穿越 支付意愿

假设每个受访者有一个潜在的和内源性的变量 u_i , 使得,

$$w_i = I(\{u_i \geq c(z_i)\})$$

$c(z)$ 为一个依赖于 z 的截止函数

不失一般性, 取 $u_i \sim \text{Unif}([0, 1])$ 均匀分布, 可得 $c(z) = 1 - P[w_i=1 | z_i=z]$
则可产生 IV:

- ① $\{Y_i(0), Y_i(1)\}$ such that. $Y_i = Y_i(w_i)$ 影响存在且通路唯一
- ② $\{Y_i(0), Y_i(1), u_i\}$ 且 z_i 异生
- ③ $c(z_i)$ 有一个非平凡的分布 相关
- ④ $c(z)$, cadlag (右侧连续), 非减的 w_i, z_i 非减

定义, marginal treatment effect 边际处理效应.

$$\tau(u) = E[Y_i(1) - Y_i(0) | u_i=u]$$

下证, IV 可找到 $\tau(u)$ 的加权平均, 在这里, 设 $z_i \sim N(0, 1)$, (IV.2) 改写为

$$\tau_{\text{LATE}} = \frac{\sum_{z \in S} \left(\int_{c^-(z)}^{c(z)} \tau(u) du \right) \varphi(z) + \int_{R \setminus S} \tau(c(z)) c'(z) \varphi(z) dz}{\sum_{z \in S} (c(z) - c^-(z)) \varphi(z) + \int_{R \setminus S} c'(z) \varphi(z) dz}$$

其中 S 是 $c(\cdot)$ 的不连续点集, $c^-(z) = \lim_{a \uparrow z} c(a)$

可看出 τ_{LATE} 是 $\tau(u)$ 的凸平均

注: $c(z)$ 为单调递增, 其也必须具有有界的变化.

所以有: $c(z) = c_0 + \int_{-\infty}^z c'(a) da$ 其中 $c'(z)$ 是某个非负的 Lebesgue 可积函数

No.

Date

#. $H'(z)$ 表示 $H(z)$ 的分布导数:

$$-H'(z) = \begin{cases} \left(\int_{c-z}^{c(z)} z(u) du \right) \delta_z, & \text{for } z \in S, \\ z(c(z)) c'(z) & \text{else.} \end{cases}$$

δ_z 是在 z 处的 Dirac 分布函数.

满足 1. $\delta(z) = 0$ when $z \neq 0$

$$2. \int_{-\infty}^{\infty} \delta(z) dz = 1$$

Example 1. Single jump and multiple jumps

当 $c(z)$ 为常数，仅有单一跳跃： $c(z) = c_0 + \delta \mathbb{1}\{z \geq z_1\}$

$$\text{则:} \begin{cases} \text{Never taker: } & u_i < c_0 \\ \text{compliers: } & c_0 \leq u_i < c_0 + \delta_1 \\ \text{always takers: } & u_i \geq c_0 + \delta_1 \end{cases}$$

当有 K 个跳跃点： $c(z) = c_0 + \sum_{k=1}^K \delta_k \mathbb{1}\{z \geq z_k\}$

$$\text{则: } \text{ATE} = \frac{\sum_{k=1}^K E[z(u_i) | c-(z_k) \leq u_i < c(z_k)] (c(z_k) - c-(z_k)) \psi(z_k)}{\sum_{k=1}^K (c(c_k) - c-(z_k)) \psi(z_k)}$$

在 $c(\cdot)$ 上的 compliers 的 ATE 由组合，
权重依赖于 u 空间中 stratum 的大小和 $\psi(z_k)$

Example 2: Continuous cutoff 连续阈值。

若 $c(z)$ 无跳跃：

$$\text{ATE} = \int_R u(c(z)) c'(z) \psi(z) dz / \int_R c'(z) \psi(z) dz$$

$$\begin{aligned} \text{协方差: } \text{Cov}[Y_i, z_i] &= \text{Cov}[Y_{i(0)} + (Y_{i(1)} - Y_{i(0)}) W_i, z_i] \\ &= \text{Cov}[(Y_{i(1)} - Y_{i(0)}) W_i, z_i] \\ &= \text{Cov}[(Y_{i(1)} - Y_{i(0)}) \mathbb{1}\{(u_i > c(z_i))\}, z_i] \\ &= \text{Cov}[z(u_i) \mathbb{1}\{(u_i > c(z_i))\}, z_i] \end{aligned}$$

令 $H(z) = E[z(u_i) \mathbb{1}\{(u_i > c(z))\}]$, z 为标准 Gaussian.

$$\text{Cov}[H(z_i), z_i] = E[H'(z_i)]$$

$$\tau = \frac{\text{Cov}[Y_i, Z_i]}{\text{Cov}[W_i, Z_i]} = \frac{E[Y_i | Z_i=1] - E[Y_i | Z_i=0]}{E[W_i | Z_i=1] - E[W_i | Z_i=0]} \quad (10.2)$$

No.

Date

$$\tau_{(u)} = E[Y_i(1) - Y_i(0) | W_i=u] \quad (10.6)$$

Estimating the marginal treatment effect 估计边际处理效应

在 (Z) 的连续点处：

$$\tau(C(Z)) = \frac{\frac{d}{dz} E[Y_i | Z_i=z]}{\frac{d}{dz} P[W_i=1 | Z_i=z]} \quad (10.12)$$

假设比率导数良好
(分子分母可微, 分母非)

下证 (10.12) .

$$E[Y_i | C(Z_i)=c] = E[Y_i(0)] + \mathbb{1}(u_i > c) (Y_i(1) - Y_i(0)) | C(Z_i)=c$$

$$= E[Y_i(0)] + \mathbb{1}(u_i > c) (Y_i(1) - Y_i(0))]$$

$$= E[Y_i(0)] + \int_c^1 \tau(u) du \quad (\text{Fubini})$$

$$\Rightarrow \tau(c) = -\frac{d}{dc} E[Y_i | C(Z_i)=c] \quad \checkmark$$

练习法：

$$\frac{d}{dz} E[Y_i | Z_i=z] = \frac{d}{dc} E[Y_i | C(Z)=c] C'(z) \quad \checkmark$$

$$\text{又假设 } u_i \sim U(0,1) \text{ 且 } Z_i \quad C'(z) = -\frac{d}{dz} P[W_i=1 | Z_i=z] \quad \checkmark$$

取立. $(10.12) \square \checkmark$